

Matriz de costos y documentación de seguridad y resiliencia

Proyecto final — Automatización de presupuestos por WhatsApp (n8n)

Alumno: __ **Materia:** __ **Fecha:** 21/09/2026

Este documento cubre dos secciones del entregable: (1) matriz de costos con justificación del modelo utilizado y (2) documentación de seguridad y resiliencia. La totalidad de los datos técnicos del workflow provienen del archivo `proyecto_final.json` provisto. Los datos del catálogo provienen del archivo `Artículos-Grid_view.csv` (tabla "Artículos" de Airtable, 50 registros, códigos 2055-2104). Los precios de los modelos de lenguaje están verificados contra documentación oficial de Anthropic y OpenAI al 21/09/2026. Donde no hay un dato medido, se indica explícitamente que se trata de una estimación.

1. Matriz de costos y justificación del modelo

1.1 Precios de referencia

Modelo	Proveedor	Input (\$/MTok)	Output (\$/MTok)	Con Batch API (~50%)
GPT-4o mini	OpenAI	\$0.15	\$0.60	\$0.075 / \$0.30
Claude Haiku 4.5	Anthropic	\$1.00	\$5.00	\$0.50 / \$2.50
Claude Sonnet 5 (modelo utilizado en el nodo <i>Anthropic Chat Model</i>)	Anthropic	\$3.00	\$15.00	\$1.50 / \$7.50
Claude Opus 5	Anthropic	\$5.00	\$25.00	\$2.50 / \$12.50

MTok = millón de tokens. Sonnet 5 tuvo precio de lanzamiento de \$2/\$10 vigente hasta el 31/08/2026; desde el 01/09/2026 rige el precio estándar de \$3/\$15 utilizado en este documento.

1.2 Punto del workflow donde interviene un modelo de lenguaje

El archivo `proyecto_final.json` tiene un único nodo que utiliza un LLM: **AI Agent**, conectado a *Anthropic Chat Model* (`claude-sonnet-5`), con tres componentes auxiliares:

- `Simple Memory` : memoria de la conversación, indexada por `wa_id` .
- Tool `ARTICULOS` : búsqueda sobre la tabla "Artículos" de Airtable.
- `Structured Output Parser` : fuerza la salida a un JSON con `usuario` , `articulos[]` , `total` , `mensaje` .

El resto de los nodos (Airtable, Gmail, WhatsApp, Telegram, los dos `IF`) son llamadas determinísticas a APIs, sin modelo de por medio. Por lo tanto, la justificación de costo se concentra en ese único nodo.

1.3 Justificación del modelo elegido

Según el `systemMessage` del nodo AI Agent, la tarea consiste en, en una sola pasada: interpretar un pedido en lenguaje informal, matchear cada ítem contra el catálogo por descripción + presentación + marca, **detectar ambigüedad y no adivinar** cuando dos artículos son igual de plausibles, calcular subtotales respetando la unidad de venta (bulto vs. unidad), y devolver el JSON estructurado con formato de WhatsApp.

Alternativa más económica	Riesgo identificado para esta tarea
GPT-4o mini (\$0.15 / \$0.60)	Mayor probabilidad de forzar un match cuando el pedido es ambiguo (ej. "coca" sin especificar presentación), en lugar de marcarlo como ambigüedad, generando un presupuesto incorrecto.
Claude Haiku 4.5 (\$1.00 / \$5.00)	Mismo ecosistema de tools que Sonnet, pero con menor capacidad de razonamiento multi-paso sobre ambigüedad. Riesgo menor que GPT-4o mini pero presente.

En un flujo cuyo output determina un monto a cobrar, el costo de un error (ítem mal matcheado, cálculo incorrecto) supera la diferencia de precio por token entre Sonnet 5 y un modelo más económico. Esto justifica el uso de Sonnet 5 para este nodo puntual.

1.4 Aplicabilidad del Batch API

No aplica. El nodo AI Agent se dispara por un `WhatsApp Trigger` : el cliente espera la respuesta dentro de una conversación en curso, sostenida por `Simple Memory` indexada por `wa_id` . El Batch API de Anthropic reduce el costo un 50% a cambio de tolerar hasta 24 hs de demora, lo cual es incompatible con una conversación de WhatsApp en tiempo real. Ningún nodo del workflow, tal como está diseñado, es candidato a batch.

1.5 Estimación de costo por presupuesto (con datos del catálogo real)

Fuente de los datos: `Artículos-Grid_view.csv`, 50 artículos (códigos 2055 a 2104), campos Código / Descripción / Unidades por bulto / Precio unitario / Precio por bulto.

Volumen de uso: 10 a 15 pedidos por día, de 5 a 10 ítems cada uno (dato aproximado provisto, no medido; se usa como base de cálculo y se señala como tal).

Metodología de estimación de tokens: no se contó con acceso al tokenizador exacto de Claude en este entorno, por lo que se usó la heurística estándar de ~4 caracteres por token. El orden de magnitud es confiable; la cifra exacta puede variar en un rango de ±20%.

Componente del prompt	Tamaño medido	Tokens estimados
<code>systemMessage</code> del AI Agent (texto fijo del JSON)	1.626 caracteres	≈ 400
Resultado de la tool <code>ARTICULOS</code> (50 artículos, JSON con metadata de Airtable — se trae una sola vez por conversación)	10.933 caracteres	≈ 2.700
Pedido del cliente (ejemplo con 8 ítems, lenguaje informal)	206 caracteres	≈ 50–150 según cantidad de ítems
Salida estructurada (<code>usuario</code> , <code>articulos[]</code> , <code>total</code> , <code>mensaje</code> ; ejemplo con 7 ítems)	880 caracteres	≈ 200–400 según cantidad de ítems

Costo del primer mensaje de una conversación (el que carga el catálogo completo; input ≈ 3.200 tokens, output ≈ 300 tokens):

Input: $3.200 / 1.000.000 \times \$3 = \$0.0096$
Output: $300 / 1.000.000 \times \$15 = \0.0045
Total por presupuesto ≈ $\$0.0141$

Proyección mensual (10–15 pedidos/día × 30 días = 300–450 presupuestos/mes):

Escenario	Presupuestos/mes	Costo mensual estimado
Piso (10/día)	300	≈ \$4.23
Techo (15/día)	450	≈ \$6.35

Conclusión de la estimación: con el volumen y el catálogo actuales, el costo de usar Claude Sonnet 5 en este workflow ronda los **\$4 a \$6 por mes**. Esa cifra es marginal frente al valor operativo de automatizar la generación de presupuestos, lo que refuerza que no hay necesidad de optimizar el modelo por costo en el estado actual del proyecto — la variable a vigilar a futuro sería el crecimiento del catálogo (cada artículo nuevo suma tokens fijos a cada conversación, porque la tool trae la lista completa).

2. Seguridad y resiliencia

2.1 Minimización de datos

Datos personales que circulan en el workflow, según `proyecto_final.json`:

- Número de WhatsApp (`wa_id`) y nombre de perfil** del cliente: ingresan por el `WhatsApp Trigger`, se usan como `sessionKey` de la memoria del AI Agent, y se almacenan en texto plano en el campo `Cliente` de la tabla Airtable "Presupuestos".
- Detalle del pedido y monto total:** se almacenan en Airtable (`Artículos` , `Total`) y se reenvían completos por correo a `leospadavecchia96@gmail.com` para la aprobación.
- Sin enmascaramiento en ningún punto:** el teléfono viaja en claro entre WhatsApp → AI Agent → Airtable → Gmail.
- Sin política de retención:** no existe ningún nodo que archive o purgue registros antiguos de la tabla "Presupuestos"; los datos se acumulan indefinidamente.
- Telegram** (notificación de rechazo al administrador) es el único canal que minimiza correctamente: solo transmite el número de presupuesto, sin datos del cliente ni del pedido.

Recomendaciones:

- Definir una retención explícita en Airtable (por ejemplo, archivar registros de más de 90 días).
- Evaluar si el campo `Cliente` requiere el nombre completo o si alcanza con un identificador interno junto a los últimos cuatro dígitos del teléfono.
- Restringir el acceso a la casilla de Gmail que recibe la aprobación (autenticación de dos factores, sin reglas de reenvío automático), dado que es el punto donde se concentra la mayor cantidad de datos personales en un solo mensaje.
- Revisar la política de retención de logs de ejecución de la instancia de n8n, que por defecto puede conservar el payload completo del `WhatsApp Trigger` (número y nombre incluidos).

2.2 Rutas de error (Error Handlers)

Nivel de nodo — AI Agent: el nodo **AI Agent** tiene `retryOnFail: true`, `maxTries: 3`, `onError: "continueErrorOutput"`. Ante tres fallos consecutivos, continúa por la segunda salida hacia el nodo *"responde que no puede procesar la solicitud"*, que informa al mismo usuario por WhatsApp. Por tener `continueErrorOutput`, este nodo no detiene la ejecución del workflow ni dispara el error workflow global descrito a continuación — su falla queda resuelta dentro del propio flujo.

Nivel de workflow — Error Workflow global (agregado): se incorporó un workflow de error global, vinculado a este workflow como su *Error Workflow* en la configuración de n8n. Se dispara automáticamente ante cualquier nodo que falle y detenga la ejecución (Airtable, Gmail, WhatsApp, Telegram — los nodos que antes no tenían manejo de errores propio) y envía un mensaje por Telegram indicando que el workflow de presupuestos falló y está pendiente de revisión humana.

Con esta incorporación, el workflow queda con dos capas de manejo de errores:

Capa	Cubre	Acción ante falla
Retry + continueErrorOutput en AI Agent	Fallas del modelo de lenguaje / la tool <code>ARTICULOS</code> dentro del AI Agent	Reintenta 3 veces; si persiste, avisa al cliente por WhatsApp que no se pudo procesar su pedido
Error Workflow global	Fallas en Airtable, Gmail, WhatsApp o Telegram que detienen la ejecución	Notifica al administrador por Telegram que el presupuesto quedó pendiente de revisión humana

Alcance actual (decisión de diseño, MVP): el Error Workflow global solo notifica al administrador; el cliente no recibe ningún mensaje en ese escenario. Es una limitación conocida y aceptada para esta etapa del proyecto — la resolución del caso queda a cargo del administrador de forma manual. Queda como mejora fuera del alcance del MVP extender la notificación al cliente.

2.3 Puntos de Human-in-the-loop

Implementado: un único punto de control humano — el nodo Gmail *"presupuesto pendiente de aprobacion humana"* (`sendAndWait`, `approvalType: double`, botones **APROBAR** / **RECHAZAR**). Se ejecuta después de que el AI Agent arma el presupuesto y antes de que se envíe al cliente. Es el punto que evita que un error del agente (artículo mal matcheado, cálculo incorrecto) llegue directo al cliente final.

No cubierto por HITL: el camino en el que el presupuesto da \$0 (`el presupuesto es mayor a 0?` → No) responde directo al cliente sin pasar por aprobación humana. Si es una decisión de diseño consciente (el mensaje es inocuo, solo informa que no se pudo procesar el pedido), corresponde documentarlo como tal en el entregable, no dejarlo como un vacío no analizado.

Precios de modelos verificados en documentación oficial de Anthropic (platform.claude.com/docs/en/about-claude/pricing) y OpenAI al 21/09/2026. Datos del workflow extraídos de `proyecto_final.json`. Datos del catálogo extraídos de `Articulos-Grid_view.csv` (50 registros). El volumen de pedidos (10-15/día, 5-10 ítems) fue provisto como estimación por el autor del proyecto, no medido; se lo señala como tal en cada cálculo donde se utiliza.